

Proyecto Integrado (EA2). Análisis de una necesidad de ingeniería de datos

Mateo Lara Aristizábal

Simón Lara Aristizábal

Proyecto Integrado V - Línea de Énfasis PREICA2502B020074

Andrés Felipe Callejas

23 de noviembre de 2025

IUDigital

Contenido

Resumen	3
Objetivos del Proyecto.....	3
Objetivo General	3
Objetivos Específicos	3
Metodología	4
Adquisición y Preparación de Datos.....	4
Modelado y Carga (ETL a SQLite)	4
Análisis Cuantitativo y Exploratorio	5
Visualización de Datos.....	6
Dinámica del Mercado y Distribución Regional.....	6
Tendencias Históricas y Producción	7
Líneas de Tiempo por Conteo.....	7
Dominancia de Plataformas y Géneros	7
Rendimiento de Publishers	8
Ranking de Ventas	8
Línea de Tiempo de Ventas Anuales	8
Resultados	9
Bibliografía:	9

Resumen

El presente estudio tiene como objetivo principal realizar un análisis exhaustivo de las ventas históricas de videojuegos a nivel mundial, desglosando el rendimiento comercial a través de tres dimensiones clave: plataformas, géneros y regiones geográficas. Se busca identificar las tendencias predominantes en el mercado, cuantificando la contribución de cada plataforma de *hardware* (e.g., PS4, Xbox, PC) y de cada categoría de *software* (e.g., Acción, Deportes, Rol) al total de ventas globales. La investigación se centra en regiones específicas como Norteamérica (NA), Europa (EU), Japón (JP) y el resto del mundo (Other) para comprender las dinámicas culturales y económicas que impulsan el consumo. Este análisis inicial es fundamental para establecer un marco de referencia cuantitativo que permita a los desarrolladores, editores y analistas de mercado tomar decisiones estratégicas informadas. Los hallazgos proporcionarán una visión clara sobre dónde y cómo se ha generado el mayor valor económico en la industria del videojuego a lo largo de los años. Este trabajo se basa en datos históricos de ventas y utiliza técnicas de minería de datos y programación Python con SQLite para su procesamiento y visualización.

Objetivos del Proyecto

Objetivo General

Analizar las ventas de los videojuegos por géneros y regiones, con el fin de identificar las tendencias históricas de consumo y las dinámicas de mercado predominantes en la industria global además de los publishers que más ventas han tenido anualmente y en general.

Objetivos Específicos

Analizar de manera integral el rendimiento histórico de ventas del mercado global de videojuegos, con el fin de cuantificar y comparar las ventas por regiones de géneros, los publishers que mas han vendido globalmente, los videojuegos mas vendidos a nivel mundial y que consolas han tenido más videojuegos anualmente

Establecer las herramientas y procedimientos de extracción, transformación y carga necesarios para migrar el dataset de ventas a una base de datos relacional (SQLite) utilizando Python.

Crear gráficos estadísticos (como líneas de tiempo, gráficos de barras, gráficos circulares o heatmaps) que representen de forma clara y efectiva los hallazgos clave del análisis de ventas (rendimiento de plataformas, distribución por género y comparación regional de ventas).

Documentar de todo el proceso analítico, desde la obtención y limpieza de los datos hasta la generación de las visualizaciones con el objetivo de asegurar la claridad y transparencia.


Metodología

Adquisición y Preparación de Datos

Lo primero que se realizó en este proyecto fue la búsqueda del Dataset el cual se tomo de la página web llamada “Kaggle”, este dataset contenía la siguiente información: Rank, Name, Platform, Year, Genre, Publisher, NA_Sales, EU_Sales, JP_Sales, Other_Sales, Global_Sales. Luego de que se tomo el dataset se hizo su respectiva limpieza, identificar y tratar valores faltantes, corregir inconsistencias en formatos de texto, convertir tipos de datos si es necesario, manejar datos atípicos y además de esto se agregaron 2 nuevas columnas para día y mes del año con valores aleatorios.

Modelado y Carga (ETL a SQLite)


Se configuró una conexión a una base de datos SQLite utilizando el módulo sqlite3 de Python. Se creó el archivo de base de datos (videogames.db). Y con el DataFrame ya limpio y transformado fue cargado completamente en la base de datos SQLite. Además se creó la tabla vgsales_clean para alojar todos los registros, cumpliendo así con el objetivo de migrar el dataset a un entorno relacional.



```
1 # Importar librerías necesarias
2 import pandas as pd
3 import sqlite3
4
5 # Leer el dataset
6 df = pd.read_csv('data/games.csv')
7
8 # Verificar la estructura de la base de datos
9 df.info()
10
11 # Limpieza de datos
12 df.dropna(inplace=True)
13 df['platform'] = df['platform'].str.lower()
14 df['publisher'] = df['publisher'].str.lower()
15 df['genre'] = df['genre'].str.lower()
16 df['year'] = df['year'].str.lower()
17 df['na_sales'] = df['na_sales'].str.lower()
18 df['eu_sales'] = df['eu_sales'].str.lower()
19 df['jp_sales'] = df['jp_sales'].str.lower()
20 df['other_sales'] = df['other_sales'].str.lower()
21 df['global_sales'] = df['global_sales'].str.lower()
22
23 # Crear nuevas columnas para día y mes del año
24 df['day'] = df['year'].str[-2:]
25 df['month'] = df['year'].str[-1]
26
27 # Guardar el dataset limpio en un archivo CSV
28 df.to_csv('data/games_clean.csv', index=False)
29
30 # Conectar a la base de datos SQLite
31 conn = sqlite3.connect('videogames.db')
32
33 # Crear la tabla vgsales_clean
34 conn.execute('CREATE TABLE vgsales_clean (rank INTEGER, name TEXT, platform TEXT, publisher TEXT, year TEXT, genre TEXT, na_sales TEXT, eu_sales TEXT, jp_sales TEXT, other_sales TEXT, global_sales TEXT, day TEXT, month TEXT)')
35
36 # Cargar los datos en la base de datos SQLite
37 df.to_sql('vgsales_clean', conn, if_exists='replace', index=False)
```

Análisis Cuantitativo y Exploratorio

Esta fase se centró en la cuantificación y la exploración inicial de las variables clave del dataset enriquecido (vgsales_clean) para comprender la estructura de los datos, identificar tendencias primarias y detectar anomalías o patrones de distribución. Se obtuvieron estadísticas descriptivas (media, desviación estándar, cuartiles) para las métricas de ventas (NA_Sales, EU_Sales, Global_Sales) y el Year de lanzamiento. Esto reveló una distribución altamente asimétrica en las ventas, con una baja media general y una alta desviación estándar. Además en la matriz de Correlación de Pearson se calculó entre las variables de ventas y el año de lanzamiento. Los hallazgos principales fueron: Alta Interdependencia Occidental: Una correlación extremadamente alta (cercana a \$1.0\$) entre NA_Sales, EU_Sales y Global_Sales, lo que implica que el éxito en un mercado occidental se replica directamente en el otro y determina el éxito global. Disparidad Japonesa: La correlación de JP_Sales con los mercados occidentales es positiva pero notablemente más baja, lo que valida la naturaleza de mercado nicho o culturalmente diferenciado de Japón. Tendencia Temporal: Una correlación débilmente negativa con el Year de lanzamiento, sugiriendo que los picos de ventas históricas (los juegos más vendidos del dataset) se concentran en años anteriores, lo que es común en datasets históricos.




Visualización de Datos


La etapa de visualización tradujo los hallazgos cuantitativos en representaciones gráficas interactivas, facilitando la identificación de patrones históricos, rankings y la dinámica del mercado.

Dinámica del Mercado y Distribución Regional

Gráficos de Barras Apiladas Demostraron que Norteamérica y Europa son los principales mercados de ingresos, y que los géneros Action y Sports son los pilares del mercado global.




Gráficos de Barras de Top y Bottom Sellers Ilustraron la disparidad extrema en ventas. Los Top 3 juegos tienen ventas que se encuentran en magnitudes completamente diferentes a las ventas de la mayoría de los títulos, mostrando que el mercado es una "ley de potencia" donde pocos juegos capturan la mayor parte de los ingresos.



Tendencias Históricas y Producción


Líneas de Tiempo por Conteo

Se limitó el análisis hasta 2015 para obtener una visión limpia del auge de la industria. Se confirmó que el periodo entre 2005 y 2010 fue el máximo histórico de lanzamientos de títulos (tanto por género como por plataforma: PS2, DS, X360), con el género Action liderando consistentemente.



Dominancia de Plataformas y Géneros


Gráficos de barras que identificaron el género dominante para las consolas con más lanzamientos (ej., Action para PS2, Misc para DS), perfilando las estrategias de contenido de las principales plataformas.



Rendimiento de Publishers


Ranking de Ventas

Visualización de los Top 10 Publishers por ventas acumuladas (hasta 2015). Esta métrica es crucial, ya que mide el impacto financiero real, no solo la cantidad de juegos publicados.



Línea de Tiempo de Ventas Anuales

Muestra la volatilidad anual en las ventas de los Top 5 Publishers. Los picos pronunciados indican el éxito de lanzamientos blockbuster o de franquicias anuales resaltando la naturaleza de la industria basada en hits.



Resultados

Bibliografía:

Video game sales. (Febrero 23 de 2025).

<https://www.kaggle.com/datasets/anandshaw2001/video-game-sales>

Welcome to Python.org. (Noviembre 19 de 2025). Python.org. <https://www.python.org/>

pandas - Python Data Analysis Library. (s.f.). <https://pandas.pydata.org/>

SQLite Home page. (s.f.). <https://www.sqlite.org/>

Matplotlib — Visualization with Python. (s.f.). <https://matplotlib.org/>

seaborn: statistical data visualization — seaborn 0.13.2 documentation. (s.f.).

<https://seaborn.pydata.org/>